

CHEATSHEET TECNICO ANALISI DATI (PANDAS, NUMPY, SEABORN, OS)

1. Importazione Librerie

- **Comando:** `import pandas as pd, import numpy as np, import seaborn as sns`
- **Spiegazione:** Carica le librerie fondamentali per la manipolazione dati, calcolo numerico e visualizzazione.

2. Working Directory

- **Comando:** `import os, os.getcwd()`
- **Spiegazione:** Restituisce il percorso della cartella di lavoro corrente.
- **Esempio:** `print(os.getcwd())`
- **Comando:** `os.chdir(path)`
- **Parametri:** path (stringa con il percorso fisico della cartella).
- **Spiegazione:** Imposta una nuova cartella di lavoro per il caricamento dei file.
- **Esempio:** `os.chdir("C:/Users/...")`

3. Caricamento Dati

- **Comando:** `pd.read_csv(filepath_or_buffer)`
- **Parametri:** filepath_or_buffer (nome o percorso del file .csv).
- **Spiegazione:** Legge i dati da un file CSV e li trasforma in un DataFrame.
- **Esempio:** `df = pd.read_csv('penguins.csv')`

4. Analisi Esplorativa

- **Attributo:** `df.shape`
- **Spiegazione:** Restituisce il numero di righe e di colonne del dataset.
- **Attributo:** `df.columns`
- **Spiegazione:** Visualizza o modifica le etichette delle colonne.
- **Esempio:** `df.columns = ['specie', 'isola', ...]`

5. Screening Strutturale

- **Metodo:** `df.info()`
- **Spiegazione:** Mostra il tipo di dato (Dtype) di ogni colonna e il conteggio dei valori non nulli per identificare anomalie.
- **Metodo:** `df.describe()`
- **Spiegazione:** Genera statistiche descrittive (media, std, min, max, quartili) per le colonne numeriche.
- **Metodo:** `df.sample(n)`
- **Parametri:** n (numero intero di righe da estrarre).

- **Spiegazione:** Estrae un campione casuale di dati per un controllo rapido del contenuto.
- **Metodo:** `df.nunique()`
- **Spiegazione:** Conta i valori univoci per ogni colonna; utile per eliminare colonne con una sola modalità.
- **Metodo:** `df.column.unique()`
- **Spiegazione:** Elenca le modalità distinte presenti in una specifica colonna.

6. Grafici Esplorativi (Data Visualization)

- **Comando:** `sns.countplot(data, x, hue)`
 - **Parametri:** data (il DataFrame), x (variabile categoriale sull'asse X), hue (variabile per la legenda/raggruppamento).
 - **Spiegazione:** Crea un grafico a barre che mostra il conteggio delle osservazioni per ogni categoria.
 - **Esempio:** `sns.countplot(data=df, x='isola', hue='specie')`
- **Comando:** `sns.histplot(data, x, kde, hue)`
 - **Parametri:** data (il DataFrame), x (variabile numerica), kde=True (aggiunge la linea della densità stimata), hue (confronto tra gruppi).
 - **Spiegazione:** Visualizza la distribuzione di una variabile numerica e la sua frequenza.
 - **Esempio:** `sns.histplot(data=df, x='massa_corporea_g', kde=True)`
- **Comando:** `sns.boxplot(data, x, y, hue)`
 - **Parametri:** data, x (variabile categoriale), y (variabile numerica), hue.
 - **Spiegazione:** Rappresenta la distribuzione dei dati tramite quartili e permette di individuare visivamente gli **outlier** (valori anomali).
 - **Esempio:** `sns.boxplot(data=df, x='specie', y='massa_corporea_g')`
- **Comando:** `sns.scatterplot(data, x, y, hue, style)`
 - **Parametri:** x e y (entrambe variabili numeriche), hue (colore), style (forma dei punti).
 - **Spiegazione:** Grafico a dispersione per analizzare la correlazione tra due misure numeriche.
 - **Esempio:** `sns.scatterplot(data=df, x='lunghezza_becco_mm', y='profondità_becco_mm', hue='specie')`
- **Comando:** `sns.pairplot(data, hue)`
 - **Parametri:** data, hue (variabile di raggruppamento).
 - **Spiegazione:** Crea una matrice di grafici per visualizzare istogrammi e scatterplot di tutte le combinazioni di variabili numeriche nel dataset.
 - **Esempio:** `sns.pairplot(df, hue='specie')`

7. Gestione Valori Mancanti (Missing Value)

- **Metodo:** `df.isna()`
- **Spiegazione:** Identifica i valori mancanti restituendo una tabella di valori booleani.
- **Metodo:** `df.isna().sum(axis)`
- **Parametri:** `axis=0` (indica di sommare scorrendo le colonne).
- **Spiegazione:** Fornisce il totale dei valori mancanti per ogni singola colonna.
- **Metodo:** `df.dropna(inplace)`
- **Parametri:** `inplace=True` (applica la modifica direttamente all'oggetto originale senza crearne una copia).
- **Spiegazione:** Elimina le righe che contengono valori mancanti.
- **Metodo:** `df.column.fillna(value, inplace)`
- **Parametri:** `value` (valore da inserire, es: `1.0`), `inplace=True`.
- **Spiegazione:** Sostituisce i valori NaN con un valore specifico scelto dall'analista.

8. Trasformazione e Categorizzazione (Data Cleaning Professionale)

- **Metodo:** `df.column.astype(dtype)`
- **Parametri:** `dtype` (tipo di dato, es: `'category'`).
- **Spiegazione:** Converte il tipo di dato di una colonna (Casting), utile per ottimizzare la memoria.
- **Funzione:** `pd.cut(x, bins, labels)`
- **Parametri:** `x` (colonna numerica), `bins` (numero di intervalli), `labels` (etichette delle classi).
- **Spiegazione:** Trasforma una variabile numerica continua in una variabile categoriale (Binning).
- **Esempio:** `pd.cut(df.massa_corporea_g, bins=3, labels=['Small', 'Medium', 'Large'])`
- **Funzione:** `pd.crosstab(index, columns, margins, normalize)`
- **Parametri:** `index` (righe), `columns` (colonne), `margins=True` (totali), `normalize='index'` (calcola frequenze condizionate rispetto alla riga).
- **Spiegazione:** Crea una tabella di contingenza per analizzare le relazioni tra variabili categoriali.